

DERS NOTU

Yapay Sinir Ağları (ANN)

ile

Physics-Informed Neural Networks (PINN)

Farkları, Sezgisel Anlatımı ve Sayısal Çözümlü Örnekler

İçindekiler

1. Giriş: Bu Dökümanda Ne Öğreneceğiz?.....	3
2. Yapay Sinir Ağı (ANN) Nedir?	4
2.1. ANN'nin Yapı Taşları	4
2.2. Bir ANN Nasıl Çalışır? (Adım Adım)	4
2.3. ANN Mimarisi — Görsel Anlatım.....	5
3. ANN için Çözümlü Sayısal Örnek.....	6
3.1. Veri Kümesi	6
3.2. Basitleştirilmiş Tek Nöronlu Hesap (El ile Adım Adım).....	6
4. Physics-Informed Neural Network (PINN) Nedir?	8
4.1. PINN'i ANN'den Ayıran Temel Fark: Otomatik Türev (Automatic Differentiation)	8
4.2. PINN'in Kayıp Fonksiyonu	8
4.3. PINN Mimarisi — Görsel Anlatım.....	9
5. PINN için Çözümlü Sayısal Örnek.....	10
5.1. Elimizdeki Veri Çok Az!.....	10
5.2. Fizik Kaybının Elle Hesabı (Tek Nokta İçin).....	10
5.3. Sonuç: ANN ile PINN'in Aynı Problemdeki Karşılaştırması	11
6. ANN ile PINN Arasındaki Farkların Özet Tablosu.....	12
7. Sonuç ve Genel Değerlendirme	13

1. Giriş: Bu Dökümanda Ne Öğreneceğiz?

Bir ANN, elindeki örneklerle bakarak “bu örüntüye benzer bir şey üret” der; veriden başka hiçbir şey bilmez. Bir PINN ise aynı zamanda “ama unutma, doğa şu kuralı asla çiğnemez” der ve bu fiziksel kuralı (genellikle bir diferansiyel denklem şeklinde) öğrenme sürecine bir ceza/kısıt terimi olarak ekler.

Bu dökümanda neler var?

Önce ANN'nin ne olduğunu, nasıl çalıştığını ve nerelerde sınırlı kaldığını göreceğiz. Ardından PINN'in bu sınırı nasıl aştığını, mimarisini ve kayıp fonksiyonunu inceleyeceğiz. Her iki konu için de elle takip edilebilen, adım adım çözülmüş birer sayısal örnek bulacaksınız. Son olarak iki yöntemi yan yana karşılaştıran bir tablo ile bitireceğiz.

2. Yapay Sinir Ağı (ANN) Nedir?

Yapay sinir ağını anlamak için önce çok basit bir benzetme yapalım.

Günlük Hayattan Benzetme

Bir öğrenciye binlerce çözülmüş matematik sorusu ve cevapları verdiğiniz düşünün. Öğrenci kuralı bilmez; sadece “bu tür soruda genelde böyle bir cevap çıkıyor” diyerek örüntüyü ezberler ve yeni bir soru geldiğinde gördüğü örneklerle dayanarak tahminde bulunur. İşte klasik bir yapay sinir ağı da tam olarak bunu yapar: kuralı bilmeden, sadece örneklerden örüntü çıkarır.

Daha teknik bir tanımla: bir yapay sinir ağı, girdi verisini (x) alıp, içindeki sayısal ağırlıkları (W) ve sapma (bias, b) değerlerini kullanarak bir çıktı ($\hat{y}$) üreten matematiksel bir fonksiyondur. Bu fonksiyon, eğitim sürecinde elindeki örnekler (gerçek veriler) ile kendi ürettiği tahminler arasındaki farkı azaltacak şekilde adım adım güncellenir.

2.1. ANN'nin Yapı Taşları

- **Girdi Katmanı (Input Layer):** Modelin dışarıdan aldığı ham bilgiler (örneğin bir evin metrekaresi, oda sayısı gibi özellikler).
- **Gizli Katmanlar (Hidden Layers):** Girdileri birleştirip dönüştüren ara hesaplama katmanları. Her gizli nöron, önceki katmandan gelen değerleri ağırlıklarla çarpıp toplar, bir sapma (bias) ekler ve sonucu bir aktivasyon fonksiyonundan (örneğin ReLU veya sigmoid) geçirir.
- **Çıktı Katmanı (Output Layer):** Modelin nihai tahminini ($\hat{y}$) verdiği katman.
- **Ağırlıklar (W) ve Sapmalar (b):** Eğitim sürecinde öğrenilen, modelin “hafızası” sayılabilecek sayısal parametreler.
- **Kayıp Fonksiyonu (Loss Function):** Modelin tahmini ile gerçek değer arasındaki farkı ölçen formül. En yaygın örneği ortalama karesel hata (MSE): $L = (\hat{y} - y)^2$.
- **Geri Yayılım (Backpropagation) ve Gradyan İnişi (Gradient Descent):** Kaybı azaltmak için ağırlıkların hangi yönde ve ne kadar değiştirileceğini hesaplayan ve uygulayan algoritma.


2.2. Bir ANN Nasıl Çalışır? (Adım Adım)

1. **İleri Yayılım (Forward Pass):** Girdi verisi katman katman ağıdan geçer, her katmanda ağırlıklarla çarpılır, toplanır ve aktivasyon fonksiyonuna girer. Sonunda bir tahmin ($\hat{y}$) elde edilir.
2. **Kayıp Hesabı:** Tahmin ($\hat{y}$) ile gerçek değer (y) karşılaştırılır, aradaki fark bir sayıya (kayıp değerine) indirgenir.

3. Geri Yayılım: Bu kayıp değerinin, ağıdaki her bir ağırlığa göre türevi (gradyanı) zincir kuralıyla hesaplanır. Bu, “bu ağırlığı artırırsam kayıp artar mı azalır mı” sorusunun cevabıdır.
4. Ağırlık Güncelleme: Her ağırlık, kaybı azaltacak yönde küçük bir adımla güncellenir ($W_{\text{yeni}} = W_{\text{eski}} - \text{öğrenme_oranı} \times \text{gradyan}$).
5. Tekrar: Bu döngü (1-4. adımlar), kayıp yeterince küçülene veya belirlenen iterasyon sayısına ulaşılan kadar binlerce kez tekrarlanır.

2.3. ANN Mimarisi — Görsel Anlatım

Aşağıdaki şekil, üç girdili, iki gizli katmanlı ve tek çıktılı basit bir ANN'nin yapısını göstermektedir. Dikkat edilmesi gereken en önemli nokta, ağıın sadece çıktıyla gerçek veri arasındaki farka (sarı kutudaki kayıp fonksiyonuna) bakarak öğrenmesidir; ortada hiçbir fiziksel/bilimsel kural yer almaz.



Şekil 1: Klasik bir Yapay Sinir Ağı'nın mimarisi. Bilgi soldan sağa akar (ileri yayılım); öğrenme sadece çıktıdaki hatadan (kayıp fonksiyonundan) beslenir.

Önemli Nokta

ANN'nin gizli katmanlarındaki hiçbir nöron, “enerji korunumu” ya da “ısı denklemi” gibi bir fiziksel kanunu bilmez. Sadece elindeki sayısal örneklerle, girdi-çıktı arasındaki istatistiksel örüntüyü taklit eder. Bu yüzden gördüğü veri aralığının dışında (extrapolasyon bölgesinde) tahminleri güvenilirmez olabilir.

3. ANN için Çözümlü Sayısal Örnek

Problem: Elimizde, bir büyüklüğün karesini ($y = x^2$) yaklaşık olarak temsil eden, gürültülü 7 adet gözlem verisi olsun. Amacımız bu verilere bakarak bir ANN'nin nasıl bir eğri öğreneceğini elle (basitleştirilmiş şekilde) görmektir.

3.1. Veri Kümesi

Aşağıdaki tabloda kullanacağımız eğitim verisi yer almaktadır (gerçek $y = x^2$ değerine küçük bir gürültü eklenmiştir):

x (girdi)	y_gerçek = x^2	y_gözlem (gürültülü)
0.5	0.25	0.55
1.0	1.00	0.60
1.5	2.25	2.45
2.0	4.00	3.70
2.5	6.25	6.75
3.0	9.00	8.80
3.5	12.25	12.65

3.2. Basitleştirilmiş Tek Nöronlu Hesap (El ile Adım Adım)

Gerçek bir ANN, çok katmanlı ve doğrusal olmayan aktivasyon fonksiyonları içerir; fakat mantığı elle görebilmek için tek bir doğrusal nöronla, en küçük kareler mantığına dayanan basit bir örnek üzerinden ilerleyelim. Modelimiz: $\hat{y} = w \cdot x + b$ olsun (w : ağırlık, b : sapma).

Başlangıç: $w = 0$ ve $b = 0$ ile başlıyoruz (rastgele ağırlık ataması ile aynı mantık). Öğrenme oranı (learning rate) $\eta = 0.01$ olsun. Tek bir veri noktası ($x=2.0$, $y=3.70$) üzerinden bir güncelleme adımını gösterelim:

$$\hat{y} = w \cdot x + b = 0 \times 2.0 + 0 = 0$$

Kayıp (kare hata): $L = (\hat{y} - y)^2 = (0 - 3.70)^2 = 13.69$

Gradyanlar (L 'nin w ve b 'ye göre kısmi türevleri):

$$\partial L / \partial w = 2(\hat{y} - y) \cdot x = 2(0 - 3.70)(2.0) = -14.80$$

$$\partial L / \partial b = 2(\hat{y} - y) = 2(0 - 3.70) = -7.40$$


Ağırlık güncellemesi (gradyan inişi: parametre = parametre - $\eta \times$ gradyan):

$$w_{yeni} = 0 - 0.01 \times (-14.80) = 0.148$$

$$b_{yeni} = 0 - 0.01 \times (-7.40) = 0.074$$

Görüldüğü gibi, sadece bu tek adımda bile w ve b sıfırdan uzaklaşıp veriye “yaklaşmaya” başladı. Bu işlem tüm veri noktaları için ve binlerce iterasyon boyunca tekrarlandığında, ağ giderek $y = x^2$ eğrisine daha çok benzeyen bir fonksiyon öğrenir (gerçek bir ANN’de bu, doğrusal olmayan aktivasyonlar ve çok daha fazla parametre sayesinde gerçek eğriye çok daha iyi uyum sağlar).

ANN Sayısal Örnek: Sadece Veriye Dayalı Öğrenme ($y \approx x^2$)



Şekil 2: Solda, eğitim başlamadan önce rastgele ağırlıklarla ANN’nin ürettiği anlamsız eğri görülüyor. Sağda, eğitim tamamlandıktan sonra ağ, veri noktalarına oldukça iyi uyan bir eğri öğrenmiş durumda. Ancak bu uyum sadece veri aralığında (0–3.5) garantilidir.

Sonuç

ANN, elindeki 7 veri noktasına bakarak $y \approx x^2$ örüntüsünü başarıyla yakaladı. Fakat ağ, “ $y = x^2$ olmalı” kuralını bilmiyor; sadece verilen noktalara en iyi uyan eğriyi buluyor. Eğer veri aralığının çok dışında (örneğin $x = 10$ için) bir tahmin istenseydi, ağın bunu doğru yapacağını hiçbir garantisi yoktur.

4. Physics-Informed Neural Network (PINN) Nedir?

Şimdi aynı benzetmeye geri dönelim, ama bu kez öğrenciye sadece soru-cevap örnekleri değil, aynı zamanda “bu konunun temel kuralını da öğreneceksin ve hiçbir cevabın bu kuralı çiğnememesi gerekiyor” talimatı verelim.

Günlük Hayattan Benzetme

Bir fizik öğretmeni öğrenciye “bu cismin konumunu tahmin et” dediğinde, sadece eski ölçümlere bakmasını istemez; aynı zamanda “unutma, Newton’un hareket kanunlarını da çiğnemeyeceksin” der. Öğrenci artık iki şeyi aynı anda dengeler: hem ölçümlere uymalı hem de fiziğin temel kurallarına aykırı bir cevap vermemeli. PINN’in mantığı tam olarak budur.

Physics-Informed Neural Network (Fizik Bilgili Sinir Ağı), bir sinir ağını eğitirken, klasik veri kaybına ek olarak, çözmeye çalıştığımız diferansiyel denklemin (genellikle bir Kısmi Diferansiyel Denklem - PDE veya Adi Diferansiyel Denklem - ODE) ne kadar “ihlal edildiğini” ölçen ek bir kayıp terimi kullanan bir yöntemdir. Bu sayede ağ, hem elindeki (genellikle çok az olan) gözlem verisine hem de fizik kanununa aynı anda uymaya zorlanır.

4.1. PINN’i ANN’den Ayıran Temel Fark: Otomatik Türev (Automatic Differentiation)

PINN’in büyük buluşu şudur: sinir ağının çıktısı $\hat{u}(x,t)$, girdilerine (x, t) göre otomatik türev (autograd) ile türetilir. Yani ağın kendisi, klasik anlamda “sayısal bir fonksiyon” olduğu için, $\partial\hat{u}/\partial x$, $\partial^2\hat{u}/\partial x^2$, $\partial\hat{u}/\partial t$ gibi türevleri analitik olarak (yaklaşıksız) hesaplamak mümkündür. Bu türevler, çözmek istediğimiz diferansiyel denklemin içine yerleştirilip bir “kalıntı (residual)” hesaplanır. Eğer ağ fiziksel kurala tam uyuyorsa bu kalıntı sıfır olmalıdır.

4.2. PINN’in Kayıp Fonksiyonu

Bir PINN’in toplam kaybı genellikle iki (bazen üç) bileşenden oluşur:


$$L_{\text{toplam}} = L_{\text{veri}} + \lambda \cdot L_{\text{fizik}} (+L_{\text{sınır/başlangıçkoşulu}})$$

- L_{veri} : Modelin tahmini ile elimizdeki (varsa) gerçek gözlemler arasındaki klasik fark (ANN’deki kayıpla aynı mantık).
- L_{fizik} : Diferansiyel denklemin kalıntısının karesi — yani modelin fizik kuralını ne kadar ihlal ettiği. Bu terim, rastgele seçilen iç noktalarda (collocation points) hesaplanır ve gerçek veri gerektirmez!
- λ : Fizik kaybının toplam kayıp içindeki ağırlığını belirleyen bir denge katsayısı.

Bu son nokta çok önemlidir: L_{fizi} terimi, etiketli veri gerektirmeden, sadece denklemin kendisinden hesaplanır. Bu sayede PINN, çok az (bazen yalnızca başlangıç/sınır koşulu kadar) veriyle bile, denklemin tüm çözüm uzayında tutarlı bir tahmin üretebilir.

4.3. PINN Mimarisi — Görsel Anlatım

Aşağıdaki şekil, klasik bir ANN mimarisine ek olarak otomatik türev ile hesaplanan fizik kaybının nasıl devreye girdiğini göstermektedir.



Şekil 3: PINN mimarisi. Sinir ağının çıktısı $\hat{u}(x, t)$, otomatik türev ile diferansiyel denklemin içine konularak bir fizik kaybı üretir. Toplam kayıp, veri kaybı ile fizik kaybının ağırlıklı toplamıdır.

Önemli Nokta

Dikkat: PINN'in ağ mimarisi (katmanlar, nöronlar) ANN ile birebir aynı olabilir! Fark, mimaride değil, **kayıp fonksiyonunda ve bu kaybın nasıl hesaplandığındadır**. PINN'i "özel" yapan şey, **otomatik türev kullanarak fiziksel denklemini doğrudan eğitim sürecine dahil etmesidir**.

5. PINN için Çözümlü Sayısal Örnek

Problem: Basit bir bozunma (exponential decay) denklemini ele alalım:

$$dy/dx = -2y, y(0) = 1$$

Bu denklemin analitik (gerçek, kesin) çözümü herkesin bildiği gibi $y(x) = e^{(-2x)}$ 'tir. Biz bu çözümü zaten bildiğimiz için, PINN'in mantığını adım adım doğrulayabiliriz.

5.1. Elimizdeki Veri Çok Az!

Gerçek mühendislik problemlerinde, deney verisi toplamak çok maliyetlidir. Bu örnekte, sadece $x = 0$ ile $x = 0.5$ arasında 4 ölçüm noktamız olduğunu varsayalım:

x	y_gözlem
0.00	1.00
0.15	0.74
0.30	0.56
0.50	0.36

5.2. Fizik Kaybının Elle Hesabı (Tek Nokta İçin)

PINN'de fizik kaybını hesaplamak için, veri noktalarından bağımsız olarak rastgele “kolokasyon noktaları” seçilir (örneğin $x_c = 1.5$) ve ağın o noktadaki çıktısı ile türevi hesaplanır. Diyelim ki eğitimin bir aşamasında ağıımız $x_c = 1.5$ noktasında şu tahminleri üretiyor (örnek/varsayımsal ara değerler):

$$\hat{u}(1.5) = 0.061, \hat{u}/dx|_{x=1.5} = -0.105 \quad (\text{otomatik türev ile hesaplanır})$$

Şimdi bu değerleri denklemimizin kalıntısında (residual) yerine koyalım. Denkleminiz $dy/dx = -2y$ olduğuna göre, kalıntı $r(x) = dy/dx + 2y$ şeklinde tanımlanır (sıfır olması beklenir):

$$r(1.5) = \hat{u}/dx + 2 \cdot \hat{u} = -0.105 + 2 \times 0.061 = -0.105 + 0.122 = 0.017$$

Bu kalıntının karesi, o noktadaki fizik kaybına katkı olur:

$$L_{\text{fizik}}(1.5) = r(1.5)^2 = (0.017)^2 = 0.000289$$

Gördüğünüz gibi kalıntı sıfıra çok yakın (0.017), bu da ağın bu noktada fizik kuralına neredeyse tam uyduğu anlamına gelir. Eğitim ilerledikçe, bu kalıntı tüm kolokasyon noktalarında sıfıra yaklaşacak şekilde ağırlıklar güncellenir — ve bu, hiçbir gerçek gözlem verisi olmayan $x = 1.5$ noktasında bile ağın doğru davranmasını sağlar!

Aynı şekilde, $x = 0$ noktasındaki başlangıç koşulu da bir kayıp terimi olarak eklenir:


$$L_{\text{başlangıç}} = (\hat{u}(0) - 1)^2$$

Toplam kayıp, tüm bu bileşenlerin (gözlem verisi + fizik kalıntısı + başlangıç koşulu) ağırlıklı toplamıdır ve eğitim, bu toplam kaybı en aza indirmeye çalışır.

5.3. Sonuç: ANN ile PINN'in Aynı Problemdeki Karşılaştırması

Aşağıdaki şekil, sadece 4 gözlem noktasıyla eğitilmiş bir ANN ile aynı 4 noktayı kullanan ama ek olarak $dy/dx = -2y$ kuralını da bilen bir PINN'in davranışını karşılaştırmaktadır.

PINN Sayısal Örnek: $dy/dx = -2y$, $y(0) = 1$ Denkleminin Çözümü



Şekil 4: Solda, sadece veriye dayanan ANN, gözlem aralığının dışına çıktığında (kırmızı bölge) gerçek çözümden tamamen sapıyor. Sağda, aynı az veriyle eğitilmiş ama fizik kuralını da bilen PINN, tüm bölgede (yeşil) gerçek çözümlle örtüşüyor.

Bu Örnekten Çıkarılacak Temel Ders

Veri her zaman pahalı ve sınırlıdır. ANN, gördüğü veri aralığının dışında "kördür"; çünkü hiçbir kural bilmez. PINN ise, az veriyle birlikte denklemin kendisini de kullandığı için, hiç veri olmayan bölgelerde bile fiziksel olarak tutarlı ve güvenilir tahminler üretebilir. Bu, özellikle deney/simülasyon verisinin pahalı olduğu mühendislik ve fizik problemlerinde (akışkanlar dinamiği, ısı transferi, malzeme bilimi vb.) PINN'i çok değerli kılar.

6. ANN ile PINN Arasındaki Farkların Özet Tablosu

Aşağıdaki tablo, bu dökümanda anlatılan tüm farkları tek bakışta karşılaştırmanız için hazırlanmıştır.

Kriter	Klasik ANN	PINN
Öğrenme kaynağı	Sadece etiketli veri (gözlemler)	Veri + fiziksel denklem (PDE/ODE)
Kayıp fonksiyonu	$L = (\hat{y} - y)^2$	$L = L_{\text{veri}} + \lambda \cdot L_{\text{fizik}}$ (+ sınır/başlangıç koşulu)
Veri ihtiyacı	Genellikle büyük miktarda etiketli veri gerekir	Çok az veriyle (hatta hiç veri olmadan) çalışabilir
Extrapolasyon (veri dışı tahmin)	Güvenilmez, örüntüyü bilmediği bölgede sapar	Fizik kuralı sayesinde veri dışında da tutarlı
Otomatik türev kullanımı	Sadece geri yayımda (ağırlık güncellemesi için)	Hem geri yayımda hem de girdiye göre türev alıp fizik kaybını hesaplamada
Tipik kullanım alanları	Görüntü tanıma, dil işleme, genel regresyon/sınıflandırma	Akışkanlar dinamiği, ısı transferi, malzeme bilimi, ters problemler
Yorumlanabilirlik / güvenilirlik	Kara kutu; fiziksel tutarlılık garantisi yok	Fiziksel kanunlarla kısıtlı; daha güvenilir ve yorumlanabilir
Mimari (katman/nöron yapısı)	Standart ileri beslemeli ağ	Genellikle ANN ile aynı; fark kayıp fonksiyonundadır

7. Sonuç ve Genel Değerlendirme

Bu dökümanda iki temel kavramı baştan sona inceledik:

- Klasik Yapay Sinir Ağları (ANN), elindeki örneklerden örüntü çıkaran, ama hiçbir bilimsel/fiziksel kural bilmeyen, tamamen veriye dayalı öğrenen sistemlerdir.
- Physics-Informed Neural Networks (PINN), aynı sinir ağı yapısını kullanır, ancak otomatik türev sayesinde diferansiyel denklemleri doğrudan kayıp fonksiyonuna ekleyerek, çok daha az veriyle ve çok daha güvenilir biçimde fiziksel sistemleri modelleyebilir.

İki sayısal örneğimizde de gördüğümüz gibi, ANN veri olduğu bölgede başarıyla, veri dışına çıkıldığında rastgele davranabiliyor. PINN ise, fizik kuralını bildiği için, veri olmayan bölgelerde bile gerçek çözümle örtüşen tahminler üretebiliyor. Bu, özellikle mühendislik, fizik ve deneysel verinin pahalı olduğu her alanda PINN'i son yıllarda hızla popüler hale getiren temel nedendir.

Aklınızda Kalsın

ANN = “Sadece veriye bak ve örüntüyü öğren.” PINN = “Veriye bak, ama asla fiziğin temel kurallarını çiğneme.”